# HybridSN 高光谱图像分类复现 · 实验报告

***论文***：*HybridSN: Exploring 3-D–2-D CNN Feature Hierarchy for Hyperspectral Image Classification*

*(Roy et al., IEEE Geoscience and Remote Sensing Letters, 17(2): 277–281, 2020)*

***数据集***：*Pavia University（PU）/ Indian Pines（IP）/ Salinas（SA）*

***作者***：*刘睿*　　***日期***：*2026-10*

## 摘要

本文复现了 HybridSN 模型在 Pavia University 数据集上的高光谱图像分类实验，并在此基础上补充了论文未涉及的三类分析：**训练样本比例对比实验、模型组件消融实验**与**邻域对照实验。**

复现结果：在 30% 训练样本、参数量 4,844,793 的配置下，测试集（25,667 个像元）总体精度 **OA = 99.949%**、平均精度 **AA = 99.922%**、Kappa = **99.933%**，与论文报告的 99.98% 处于同一水平。

在此基础上，本实验进一步发现：① 移除 Dropout 使 OA 下降 0.043 pp（错分像元由 13 增至 24）；② 移除整个 2-D 卷积阶段仅使 OA 下降 0.012 pp，但 AA 下降 0.044 pp；③ **一个参数几乎相同的纯 2-D-CNN baseline（参数量 −1.0%）取得了相当的 OA 与更高的 AA，且计算量仅为 HybridSN 的 25%**；④ 通过光谱角与混淆矩阵的交叉分析，**发现"光谱形状相似度"并不能预测分类混淆**，真正决定混淆的是类内离散度与均值差的比值；⑤ ⭐ **在参数量与计算量完全不变的条件下，将 patch 的有效邻域由 32.5 m 缩减至 14.3 m（25×25 输入的 中心 11×11 置零），使 OA 由 99.949% 提升至 99.977%、错分像元由 13 降至 6（减少 54%）**，并通过对“直接缩小 patch”的对照实验，**分离出「邻域污染型」与「光谱相似型」两类混淆机制 —— 二者的优化方向相反。**

## 一、研究背景与论文理解

***论文要解决什么问题：***2-D-CNN：只提取空间特征，光谱信息利用不充分，3-D-CNN：能提取光谱空间联合特征，但计算量大、参数量大。通过先进行 3DCNN 后使用 2DCNN，充分吸收优点

### 1.1 模型结构（复现对象）

```
输入 patch (15, 25, 25)                    ← 15 个 PCA 主成分
   ↓ unsqueeze(1)
(N, 1, 15, 25, 25)
   ↓ Conv3d(1→8,  (7,3,3)) + ReLU          ← 光谱核 7：跨 7 个波段建模
   ↓ Conv3d(8→16, (5,3,3)) + ReLU          ← 光谱核 5
   ↓ Conv3d(16→32,(3,3,3)) + ReLU          ← 光谱核 3
(N, 32, 3, 19, 19)
   ↓ view → (N, 96, 19, 19)
   ↓ Conv2d(96→64, (3,3)) + ReLU           ← 2-D 卷积：抽象空间特征
```

```
(N, 64, 17, 17) → flatten → (N, 18496)
   ↓ Linear(18496→256) + ReLU + Dropout(0.4)
   ↓ Linear(256→128)  + ReLU + Dropout(0.4)
   ↓ Linear(128→9)
```

**参数量 4,844,793；mult-adds 50.95 M。**

其中卷积层占 **90.6% 的 FLOPs**，但第一个全连接层 `dense1` 独占 **97.7% 的参数量。**

## 二、实验环境

| 项目 | 配置 |
|---|---|
| **操作系统** | Windows 11 Pro（build 26100） |
| **CPU / 内存** | Intel i5-12600KF（10 核 16 线程）/ 31.8 GB |
| **GPU** | NVIDIA RTX 5060（8151 MiB，sm_120） |
| **驱动 / CUDA** | 610.62 / CUDA UMD 13.3 |
| **Python** | 3.10.0（pyenv-win） |
| **深度学习框架** | **PyTorch 2.10.0+cu130**、torchvision 0.25.0+cu130 |
| **其它依赖** | numpy 2.2.6、scipy 1.15.3、scikit-learn 1.7.2、matplotlib 3.10.9、spectral 0.22.4、torchinfo 1.8.0 |

> *论文基于 PyTorch 1.9.0 + CUDA 11.1；本复现因 RTX 5060（sm_120）无法使用旧版 CUDA，故采用 PyTorch 2.10.0 + CUDA 13.0。已通过固定随机种子、对齐超参数与数据划分方式控制影响。*
>
> *详细环境说明见 `环境说明.md`，依赖清单见 `依赖与框架清单.md`。*

## 三、数据集与数据探索

### 3.1 数据集概况

| 项目 | 值 |
|---|---|
| **影像尺寸** | **610 × 340** 像元 |
| **波段数** | **103**（ROSIS 传感器，430–860 nm） |
| **类别数** | **9** |
| **有标注像元总数** | **42,776** |

**各类像元数**（全图统计）：

| # | 类别 | 像元数 | 占比 |
|---|---|---|---|
| **1** | Asphalt（沥青） | 6,631 | 15.5% |
| **2** | **Meadows（草地）** | **18,649** | **43.6%** |
| **3** | Gravel（砾石） | 2,099 | 4.9% |
| **4** | **Trees（树）** | 3,064 | 7.2% |

| | | | |
|---|---|---|---|
| **5** | Painted metal sheets（金属板） | 1,345 | 3.1% |
| **6** | Bare Soil（裸土） | 5,029 | 11.8% |
| **7** | Bitumen（沥青毡） | 1,330 | 3.1% |
| **8** | Self-Blocking Bricks（砖） | 3,682 | 8.6% |
| **9** | Shadows（阴影） | 947 | 2.2% |
| | **合计** | **42,776** | 100% |

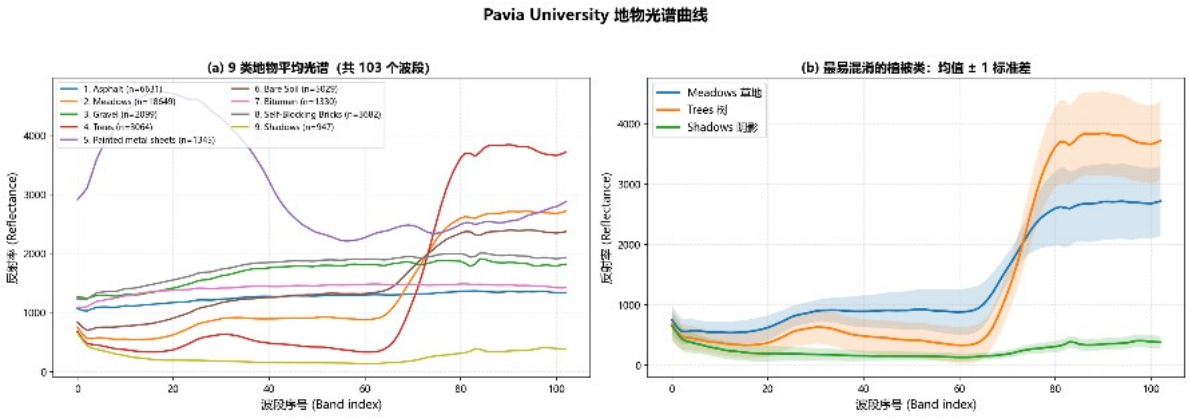
> ***类别严重不平衡***：*最大类 Meadows 是最小类 Shadows 的 **19.7 倍** —— 这是 OA 与 AA 出现差异的根本原因。*

### 3.2 数据划分

| 集合 | 像元数 | 占比 | 用途 |
|---|---|---|---|
| **训练集** | **12,832** | 30% | 更新模型权重（每轮用一次 × 100 轮） |
| **验证集** | **4,277** | 10% | 挑选最佳模型、监控过拟合（每 5 轮一次） |
| **测试集** | **25,667** | 60% | **最终评分，仅使用一次** |

划分采用 `stratify` 分层抽样保证各类比例一致，划分种子 `random_state = 100`。

### 3.3 ⭐ 地物光谱曲线分析




**图注**：(a) 9 类地物的平均光谱曲线（103 波段）；(b) 最易混淆的植被类（Meadows / Trees / Shadows）的均值 ± 1 标准差。

> *⚠ 纵轴数值为 uint16 存储的辐射值，除以 10000 即为物理反射率（0.05–0.40）。*

**三点观察**：

**① 波段 65–70 存在集体拐点（"红边"效应）**

所有植被类（Trees、Meadows、Shadows）在 band ≈ 65 后急剧上升，对应植被在 680–750 nm 的反射率陡增。**说明近红外波段是区分植被与非植被的关键区域。**

**② Painted metal sheets 的光谱形状独一无二**

它是唯一"可见光区反射率高、随波长下降"的地物（band 0 约 2900 → band 55 最低约 2100 → 回升至 2800）。

这解释了为什么它**只有 1,345 个样本（第 3 小类）却取得 100% 的召回率 —— 判别信息的独特性比样本数量更重要。**

**③ Trees 与 Meadows 的曲线形状高度相似，但 Trees 的类内离散度最大**

- 两者均在可见光区反射率低、红边后跃升至近红外平台
- 但 **Trees 的 ±1σ 区间最宽**（近红外区约 2800–4400，宽度约 1600），Meadows 约 2100–3200（宽度约 1100）
- **"均值相近 + 类内离散度大" → 分布尾部互相侵入**，这是后续混淆的直接来源

### 3.4 ⭐ 类间光谱角分析

对 9 类地物的平均光谱两两计算**光谱角**（Spectral Angle，尺度不变的形状相似度度量，越小越像），共 36 对。

**最相似的 7 对**：

| 排名 | 配对 | 光谱角 | 测试集实际错分 |
|---|---|---|---|
| **1** | Gravel ↔ Self-Blocking Bricks | **0.96°** | **0** |
| **2** | Asphalt ↔ Bitumen | **1.81°** | **0** |
| **3** | Asphalt ↔ Self-Blocking Bricks | 3.09° | **0** |
| **4** | Asphalt ↔ Gravel | 3.28° | **0** |
| **5** | Bitumen ↔ Self-Blocking Bricks | 3.86° | **0** |
| **6** | Gravel ↔ Bitumen | 4.18° | **0** |
| **7** | Meadows ↔ Bare Soil | 11.03° | **0** |
| **8** | **Trees ↔ Meadows** | **15.74°** | ⚠ **10** |

**核心发现**：

***光谱角最小的 7 对地物（0.96°–11.03°）在测试集上均未产生任何错分；*

*而第 8 对 Trees ↔ Meadows（15.74°）是第一个出现混淆的配对。 ***

**这构成一个反直觉的结论**：光谱形状"极其相似"（如 Gravel 与 SBB 仅差 0.96°）**并不必然导致分类混淆。**

**Trees 的最近邻分析**（解释错分方向）：

| 与 Trees 配对 | 光谱角 | 相对第 1 名的距离 |
|---|---|---|
| **Meadows** | **15.74°** | — |
| **Bare Soil** | 26.53° | **远 69%** |
| **Shadows** | 34.75° | 远 121% |
| **SBB / Gravel / Asphalt / Bitumen** | 42–44° | — |
| **Painted metal sheets** | 53.83° | 远 242% |

***Trees 的最近邻是 Meadows，而第二近的 Bare Soil 一下子远了 69%。***

***因此 Trees 一旦被推向邻类，其唯一合理去向就是 Meadows ——***

*这与混淆矩阵中"12 例 Trees 错分有 10 例流向 Meadows"的观测一致。*

## 四、基线复现结果

### 4.1 复现配置

| 超参数 | 值 |
|---|---|
| **数据集** | PU |
| **PCA 主成分数** | 15（`whiten=True`） |
| **Patch 尺寸** | 25 × 25 |
| **训练 / 验证 / 测试比例** | 30% / 10% / 60% |
| **Batch Size** | 256 |
| **优化器** | Adam（lr = 0.001，weight_decay = 1e-6） |
| **损失函数** | CrossEntropyLoss |
| **Epoch** | 100（每 5 轮验证一次） |
| **随机种子** | 666（`random` / `numpy` / `torch` / `cuda` 全部固定） |

### 4.2 精度结果

| 指标 | 本次复现 | 论文报告（UP） | 作者代码复现 |
|---|---|---|---|
| **OA** | **0.999494** | 0.9998 ± 0.0000 | 0.99973 |
| **AA** | **0.999225** | 0.9997 | 0.99956 |
| **Kappa** | **0.999329** | 0.9998 | 0.99964 |

| | | | |
|---|---|---|---|
| **测试样本数** | 25,667 | 42,776（全图） | 25,667 |
| **参数量** | 4,844,793 | 4.84 M | 4,844,793 |

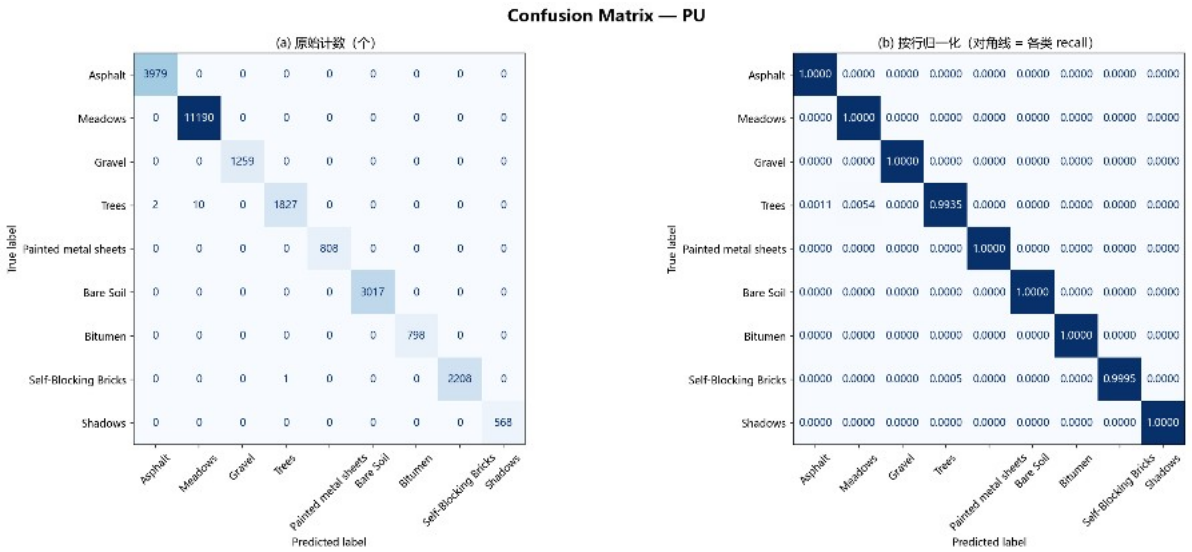
**逐类精度**：

| 类别 | precision | recall | f1-score | 支持数 |
|---|---|---|---|---|
| **Asphalt** | 0.9995 | 1.0000 | 0.9997 | 3,979 |
| **Meadows** | 0.9991 | 1.0000 | 0.9996 | 11,190 |
| **Gravel** | 1.0000 | 1.0000 | 1.0000 | 1,259 |
| **Trees** | **0.9989** | **0.9935** | **0.9962** | 1,839 |
| **Painted metal sheets** | 1.0000 | 1.0000 | 1.0000 | 808 |
| **Bare Soil** | 1.0000 | 1.0000 | 1.0000 | 3,017 |
| **Bitumen** | 1.0000 | 1.0000 | 1.0000 | 798 |
| **Self-Blocking Bricks** | 1.0000 | 0.9995 | 0.9998 | 2,209 |
| **Shadows** | 1.0000 | 1.0000 | 1.0000 | 568 |
| **合计** | — | — | — | **25,667** |

**9 类中有 7 类取得 100% 召回率，仅 Trees（12 例错分）与 Self-Blocking Bricks（1 例）存在误差。**

> ***复现结论***：*本复现 OA 与论文差距 0.03 pp、与作者代码差距 0.024 pp，**差异源于测试集划分不同***（论文在全部 42,776 个标注像元上评估，本复现仅用 60% 测试集）。***复现成功。***

### 4. 3 ⭐ 混淆矩阵分析




**混淆矩阵（行 = 真实类别，列 = 预测类别，单位：像元数）**：

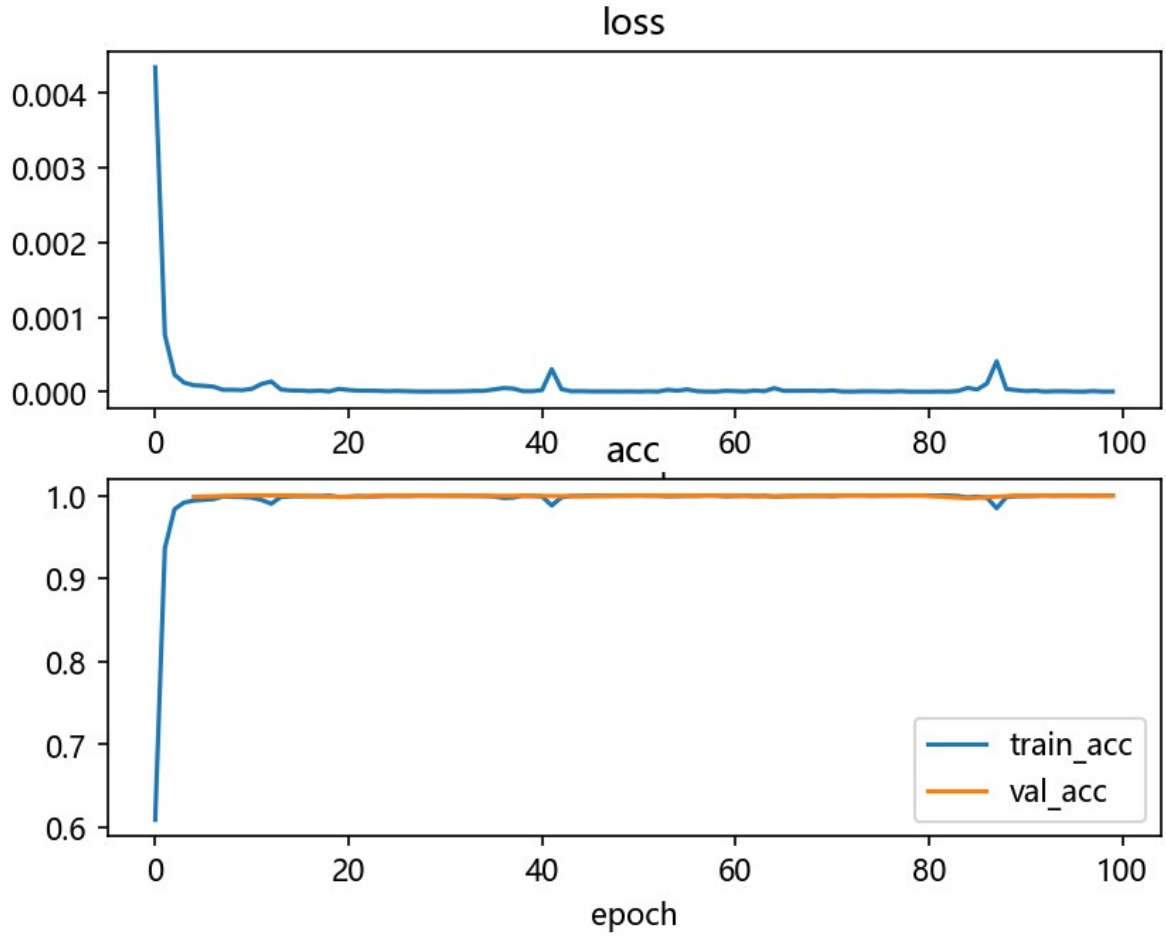
| 真实 \ 预测 | Asphalt | Meadows | Gravel | Trees | Painted | Bare Soil | Bitumen | SBB | Shadows | 合计 |
|---|---|---|---|---|---|---|---|---|---|---|
| **Asphalt** | **3979** | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 3979 |
| **Meadows** | 0 | **11190** | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 11190 |
| **Gravel** | 0 | 0 | **1259** | 0 | 0 | 0 | 0 | 0 | 0 | 1259 |
| **Trees** | **2** | **10** | 0 | **1827** | 0 | 0 | 0 | 0 | 0 | 1839 |
| **Painted** | 0 | 0 | 0 | 0 | **808** | 0 | 0 | 0 | 0 | 808 |
| **Bare Soil** | 0 | 0 | 0 | 0 | 0 | **3017** | 0 | 0 | 0 | 3017 |
| **Bitumen** | 0 | 0 | 0 | 0 | 0 | 0 | **798** | 0 | 0 | 798 |
| **SBB** | 0 | 0 | 0 | **1** | 0 | 0 | 0 | **2208** | 0 | 2209 |
| **Shadows** | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | **568** | 568 |
| **合计** | 3979 | 11200 | 1259 | 1840 | 808 | 3017 | 798 | 2208 | 568 | **25667** |

⭐ **关键特征：整个 9×9 = 81 个格子中，只有 3 个非对角格子非零！**

| # | 混淆路径 | 数量 | 占比 |
|---|---|---|---|
| **1** | **Trees → Meadows** | **10** | **76.9%** |
| **2** | Trees → Asphalt | 2 | 15.4% |
| **3** | Self-Blocking Bricks → Trees | 1 | 7.7% |
| | **合计** | **13** | 100% |

**说明**：25,667 个测试像元中仅 13 例错分，且**全部集中在 3 条混淆路径上** —— 说明模型学到的是系统性的判别规律，而非随机误差。

### 4.4 训练过程




| 项目 | 值 |
|---|---|
| **最佳模型** | `epoch_79_acc_1.0000.pth` |
| **最佳验证精度** | 1.0000 |
| **最终训练 loss** | $2.70 \times 10^{-6}$ |
| **最终训练 acc** | 0.99992 |
| **训练 acc − 测试 OA** | **0.00043（0.043 pp）** |

> ***训练集与测试集精度差距仅 0.043 pp，说明过拟合极为轻微 ——***
>
> *这为后续消融实验的解读提供了重要背景：**在一个几乎不过拟合的任务上，正则化手段的作用空间本就有限。***

⭐ **训练稳定性观察（消融实验中进一步量化）**：

训练 loss 在 epoch 86–89 附近出现尖峰。在**保留 Dropout** 的配置下尖峰量级为 $10^{-4}$；而在**移除 Dropout** 后，同一位置出现 loss 放大 224 万倍、数值接近 `ln(9) = 2.197` 的**灾难性崩塌**（详见 6.1 节）。

## 五、对比实验：训练样本比例的影响

### 5.1 实验设计

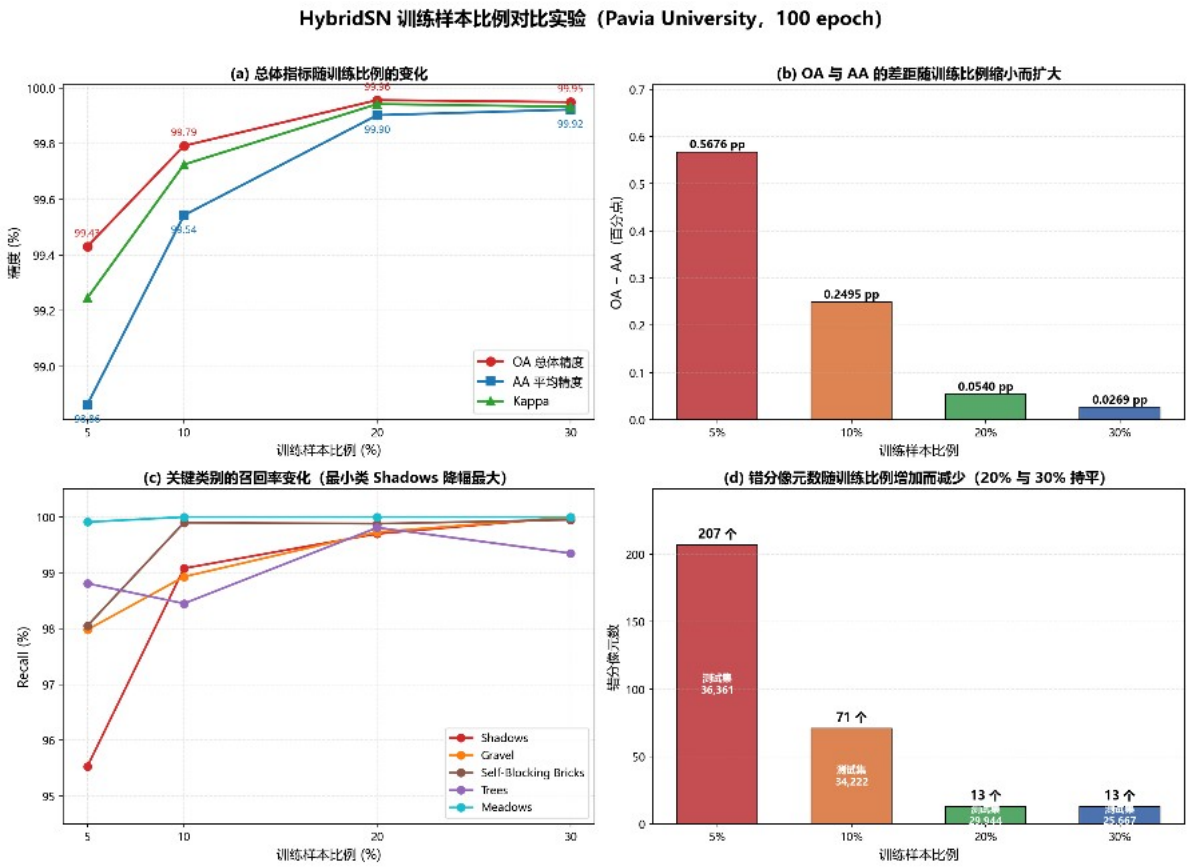
固定模型结构与全部超参数，仅改变训练样本比例，考察样本量对性能的影响。

| 组 | 训练比例 | 训练样本 | 测试样本 |
|---|---|---|---|
| **1** | 5% | 2,139 | 36,361 |
| **2** | 10% | 4,277 | 34,222 |
| **3** | 20% | 8,554 | 29,944 |
| **4** | **30%** | **12,832** | **25,667** |

> ⚠ ***注意***：*由于划分方式为"先取训练集、再从剩余部分按 1:6 分验证/测试"，*
>
> ***训练比例越低，测试集反而越大***，*因此四组的测试集规模不同。*

### 5.2 结果

| 指标 | 5% | 10% | 20% | 30% |
|---|---|---|---|---|
| **OA** | 0.994307 | 0.997925 | **0.999566** | 0.999494 |
| **AA** | 0.988631 | 0.995430 | 0.999026 | **0.999225** |
| **Kappa** | 0.992458 | 0.997250 | 0.999425 | 0.999329 |
| **错分像元数** | **207** | **71** | **13** | **13** |
| **测试样本数** | 36,361 | 34,222 | 29,944 | 25,667 |
| **OA − AA** | 0.5676 pp | 0.2495 pp | 0.0540 pp | **0.0269 pp** |
| **最佳模型** | epoch 74 | epoch 64 | epoch 94 | epoch 79 |




## 5.3 分析结论

### ① 精度随训练样本增加而提升，但边际收益递减

```
5% → 10% : OA +0.3618 pp
10% → 20%: OA +0.1641 pp
20% → 30%: OA −0.0071 pp   ← 已饱和
```

### ② ⭐ OA 与 AA 的差距单调扩大（最重要发现）

```
OA − AA : 0.0269 → 0.0540 → 0.2495 → 0.5676 pp
          (30%)    (20%)    (10%)    (5%)
放大倍数:   1.0×     2.0×     9.3×     21.1×
```

***训练样本越少，OA 与 AA 的背离越严重。***

***含义***：*样本减少时，模型优先"牺牲"少数类以保住多数类 ——*

***OA 会掩盖少数类的失效，而 AA 能暴露它。***

*这是本实验对"为何必须同时报告 OA 与 AA"的直接实证。*

### ③ 少数类与易混类最先退化

| 类别 | 5% recall | 30% recall | 退化幅度 |
|---|---|---|---|

| | | | |
|---|---|---|---|
| **Shadows（47 训练样本）** | 95.53% | 100% | **−4.47 pp** |
| **Gravel（105）** | 97.98% | 100% | −2.02 pp |
| **Self-Blocking Bricks（184）** | 98.05% | 99.95% | −1.90 pp |
| **Trees（153）** | 99.08% | 99.35% | −0.27 pp |

**④ ⚠ 但"样本少"并非退化唯一原因**

**Bitumen（约 67 个训练样本）与 Painted metal sheets（约 67 个）在 5% 配置下仍保持 100% 召回率 ——**

说明**判别信息的独特性比样本数量更重要**（与 3.3 节光谱曲线的观察一致）。

**⑤ 误差构成的变化**

| 混淆路径 | 5% | 30% |
|---|---|---|
| **Shadows 类内错分** | 17 例 | 0 |
| **Gravel → 其他** | 25 例 | 0 |
| **SBB → 其他** | 43 例 | 1 |
| **Trees → Meadows** | 有 | **10** |

> ***Trees 是四个训练比例下均未取得 100% 召回率的类别之一**：*
>
> *训练样本由 2,139 增至 12,832（6 倍），Trees 召回率由 95.53% 提升至 99.35%，*
>
> *但**始终未能消除全部错分**。*
>
> *结合 3.4 节的光谱角分析（Trees 的最近邻为 Meadows，而第二近的 Bare Soil 远 69%），*
>
> *推测该混淆具有**结构性**（源于光谱相似性与空间相邻），**仅靠增加样本量难以完全消除**。*
>
> *（⚠ 本实验未保存 5%/10%/20% 三组的混淆矩阵，故该推断尚缺直接证据。）*

## 六、消融实验

### 6.1 实验设计

论文**未提供任何组件消融证据**。本实验补充四组配置：

| 组 | 配置 | 改动 |
|---|---|---|
| **基线** | 完整 HybridSN | — |
| **消融①** | 移除 Dropout | `nn.Dropout(p=0.4)` → `p=0.0` |

| | | |
|---|---|---|
| **消融②** | 移除 2-D 卷积阶段（= 纯 3-D） | `conv4` → `nn.Identity()` |
| **消融③** | 纯 2-D-CNN baseline | 光谱维作输入通道，4 层 Conv2d |

**控制变量**：数据集、随机种子、划分种子、全部超参数与测试集（均为 25,667 个像元）完全一致。

### 6.2 结果总表

| 指标 | 基线 | 消融① 无 Dropout | 消融② 纯 3-D | 消融③ 纯 2-D |
|---|---|---|---|---|
| **Total params** | 4,844,793 | 4,844,793 | 8,926,393 | **4,794,681** |
| **ΔParams** | — | 0% | +84% | **−1.0%** |
| **Total mult-adds** | 50.95 M | 50.95 M | 39.09 M | **12.84 M** |
| **ΔFLOPs** | — | 0% | −23% | **−75%** |
| **OA** | **0.999494** | 0.999065 | 0.999377 | 0.999377 |
| **AA** | 0.999225 | 0.998496 | 0.998783 | **0.999710** |
| **Kappa** | **0.999329** | 0.998761 | 0.999174 | 0.999174 |
| **错分像元** | **13** | 24 | 16 | 16 |
| **OA − AA** | +0.0269 pp | +0.0569 pp | +0.0594 pp | **−0.0333 pp** |
| **最佳模型** | epoch 79 | epoch 84 | epoch 49 | epoch 89 |

**逐类错分分解**：

| 类别 | 基线 | 消融① | 消融② | 消融③ |
|---|---|---|---|---|
| **Trees** | 12 | 15 | **12** | **1** |
| **Meadows** | **0** | 0 | **0** | **13** |
| **Self-Blocking Bricks** | 1 | 8 | 2 | 2 |
| **Shadows** | 0 | 1 | 2 | 0 |
| **合计** | **13** | **24** | **16** | **16** |

### 6.3 分析结论

**① Dropout 是有效的正则化手段**

移除 Dropout 使 OA 下降 **0.0429 pp**、错分像元由 13 增至 **24（+85%）**，且 AA 降幅（0.0729 pp）为 OA 的 **1.70 倍。**

**这补上了论文未报告也未验证的一项超参数证据。**

**② 移除 2-D 卷积对总体精度贡献有限，但对类别均衡有明显影响**

```
OA  仅降 0.0117 pp（3 个像元）
AA  降 0.0442 pp（降幅  OA 的 3.78 倍）
OA − AA 由 0.0269 pp 扩大至 0.0594 pp（2.21 倍）
```

退化集中在最小类 **Shadows** 与易混类 **Self-Blocking Bricks。**

**③ ⭐ 一个反直觉结果：参数量 +84% 却精度略降**

消融② 的参数量比基线多 4.08 M（+84%）、计算量低 23%，**但三项指标全面略差。**

说明 **2-D 卷积阶段提供的空间特征提取能力无法由全连接层的容量替代**；

同时说明 2-D 卷积是一个"**参数少但计算密集**"的模块。

**④ ⭐ ⭐ 关键发现：纯 2-D-CNN 与 HybridSN 性能相当，且计算量仅 1/4**

在**参数量几乎对等（−1.0%）**的条件下：

| 维度 | HybridSN | 纯 2-D-CNN | 判断 |
|---|---|---|---|
| **OA** | **0.999494** | 0.999377 | 差 3 个像元（噪声边缘） |
| **AA** | 0.999225 | **0.999710** | **纯 2-D 更高 0.0485 pp** |
| **计算量** | 50.95 M | **12.84 M** | **纯 2-D 仅 25%** |

> ***结论***：*在本实验协议（PU 数据集、30% 训练样本）下，*
>
> ***"3-D + 2-D 混合结构优于单一 2-D 结构"这一主张未获得支持*** *——*
>
> *3-D 卷积带来的精度增益不足以补偿其约 4 倍的计算开销。*
>
> ***由于参数量已对齐（−1.0%），该差异不能被"模型容量"解释。***
>
> ⚠ ***边界说明***：*该结论仅在 PU + 30% 训练协议下成立，*
>
> ***不能外推****到小样本场景（5% 时 3-D 卷积的增益可能显著）或其它数据集。*

**⑤ ⭐ ⭐ 一个教科书级的现象：两模型 OA 完全相同，AA 相差 0.093 pp**

消融② 与消融③ 的 **OA 逐位相同**（均为 0.9993766314723186），因为**两者恰好都是 16 个错分像元**

——

而 OA 只取决于"错了几个"，不取决于"错在哪"。

但两者的**误差分布几乎相反**：

| 类别 | 消融②（纯 3-D） | 消融③（纯 2-D） |
|---|---|---|
| **Trees** | **12** | **1** |
| **Meadows** | **0** | **13** |
| **合计** | 16 | 16 |

**→ 导致 AA 相差 0.0927 pp（0.998783 vs 0.999710）。**

***这是"为何不能只看 OA"的最佳实证**：若仅报告 OA，会误认为两个结构迥异的模型性能完全相同；*

***加入 AA 才揭示出二者失败模式的本质差异。***

**⑥ 系统性规律：3-D 卷积与 Trees 类误差的绑定**

| 配置 | 有 3-D 卷积? | Trees 错分 | Meadows 错分 |
|---|---|---|---|
| **基线** | ✅ | 12 | 0 |
| **消融①** | ✅ | 15 | 0 |
| **消融②** | ✅ | 12 | 0 |
| **消融③** | ❌ | **1** | **13** |

***三次含 3-D 卷积的实验均呈现"Trees 错 12–15、Meadows 零错"的同一模式，***

***而唯一不含 3-D 卷积的配置误差分布完全反转。***

*这提示 **3-D 卷积的光谱方向卷积使模型倾向于把边界植被像元归入样本最多的 Meadows 类。***

### 6.4 ⭐ 训练稳定性：Dropout 抑制训练尖峰

| 配置 | 最大 loss 尖峰 | 尖峰位置 | 验证精度表现 |
|---|---|---|---|
| **基线（有 Dropout）** | ~$10^{-4}$ | ~epoch 5 / 41 / 86 | 轻微波动 |
| **消融②（有 Dropout）** | $1.146 \times 10^{-4}$ | epoch 86 | 正常波动 |
| **消融③（有 Dropout）** | $1.828 \times 10^{-4}$ | epoch 95 | 波动较大（0.977–1.000） |
| **消融①（无 Dropout）** | **$9.165 \times 10^{-3}$** | **epoch 89** | **崩塌至 0.9507，未完全恢复** |

**消融① 在 epoch 89 的崩塌细节**（数据来自 `loss.csv` / `train_acc.csv` / `val_acc.csv`）：

| 指标 | 崩前（epoch 84–87） | epoch 89 | 变化 |
|---|---|---|---|
| **loss（CSV 原值）** | ~$4.1 \times 10^{-9}$ | **$9.165 \times 10^{-3}$** | **放大 224 万倍** |
| **loss（换算真实尺度）** | ~$1.0 \times 10^{-6}$ | **≈ 2.31** | — |
| **train_acc** | 1.0000 | **0.7788** | −22.1 pp |

| | | | |
|---|---|---|---|
| **val_acc** | 0.99953 | **0.95066** | −4.89 pp |

> ***关键**：真实 loss ≈ 2.31，几乎等于 `ln(9) = 2.197` —— 即"模型退化为输出 9 类均匀概率"时的损失值。*
>
> ***说明模型的有效判别能力在 epoch 89 几乎被完全摧毁**，此后经约 10 轮部分恢复，*
>
> ***但到第 99 轮仍未回到崩前水平**（loss 2.4 × $10^{-7}$ 仍比崩前高约 60 倍）。*

**三点结论**：

| # | 观察 | 说明 |
|---|---|---|
| **1** | 有 Dropout 的三次运行尖峰均在 $10^{-4}$–$10^{-5}$ 量级；无 Dropout 时为 $10^{-3}$ 量级 | **相差 1–2 个数量级，Dropout 显著抑制训练尖峰** |
| **2** | 四个配置的尖峰均出现在训练后期（约 epoch 86–95） | 提示触发因素可能来自数据或优化过程本身，而非特定结构 |
| **3** | **检查点机制避免了一次性能损失** | 消融① 的最佳模型 epoch_84（**崩溃之前**）被选中；若无"每 5 轮保存 + 选验证最优"的机制，将使用崩塌后 val_acc 仅 0.99813 的模型 |

## 七、综合讨论

### 7.1 三条证据链的交叉验证

本实验通过**三个独立视角**分析同一个混淆现象（Trees ↔ Meadows）：

```
【视角 1：光谱层面】光谱曲线 + 光谱角
  ├─ Trees 与 Meadows 曲线形状高度相似（光谱角 15.74°）
  ├─ Trees 的类内离散度最大（±1σ 宽约 1600，为全图最宽）
  └─ Trees 的最近邻是 Meadows，第二近的类 69%
            ↓
【视角 2：模型面】消融
  ├─ 含 3-D 卷积的三次实验：Trees 错 12–15、Meadows 错 0
  └─ 不含 3-D 卷积的配置：Trees 错 1、Meadows 错 13（完全反转）
            ↓
【视角 3：结果层面】混淆矩阵
  └─ 13 例错分中 10 例（76.9%）为 Trees → Meadows
```

**三条证据互相印证，形成完整闭环。**

### 7.2 ⭐ 核心结论：光谱相似度不能预测混淆

本实验最重要的发现是**推翻了"光谱像 → 会混"这一朴素直觉**：

| 配对 | 光谱角 | 类内离散度 | 实际错分 |
|---|---|---|---|
| **Gravel ↔ Self-Blocking Bricks** | **0.96°**（极像） | 小 | **0** |
| **Asphalt ↔ Bitumen** | **1.81°**（极像） | 小 | **0** |
| **Trees ↔ Meadows** | 15.74°（不算最像） | **大**（Trees 最宽） | **10** |

**决定混淆的是「均值差 ÷ 类内波动」，而非「均值差」本身**：

- Gravel 与 SBB **均值几乎重合，但类内足够紧** → 分布不重叠 → 零错分
- Trees 与 Meadows **均值差不算小，但 Trees 类内方差极大** → 分布尾部互相侵入 → 10 例错分

### 7.3 对"为何少数类会先失效"的解释

结合 5.3 节的观察（训练样本减少时少数类先退化）与 6.2 节的观察（移除正则化后少数类退化更严重）：

> ***正则化手段（Dropout）与充足样本的共同作用，是"压缩类内分布"。***
>
> *一旦失去其中之一，类内方差增大 → 分布尾部侵入邻类 → 少数类/易混类先失效。*
>
> ***AA（类别等权）对这一过程远比 OA（样本数加权）敏感。***

### 7.4 对论文主张的总体评价

| 论文主张 | 本实验的验证结果 |
|---|---|
| **混合结构能提升精度** | ⚠ **部分支持** —— 在 PU + 30% 协议下，纯 2-D 取得相当精度且计算量仅 1/4 |
| **3-D 与 2-D 卷积互补** | ⚠ **缺少直接证据** —— 论文未做组件消融；本实验显示 2-D 卷积对总体精度贡献有限（3 个像元） |
| **模型轻量（4.84 M）** | ✅ **支持** —— 与作者一致 |
| **在三个数据集上优于对比方法** | 🟡 **本实验未验证 IP/SA** |

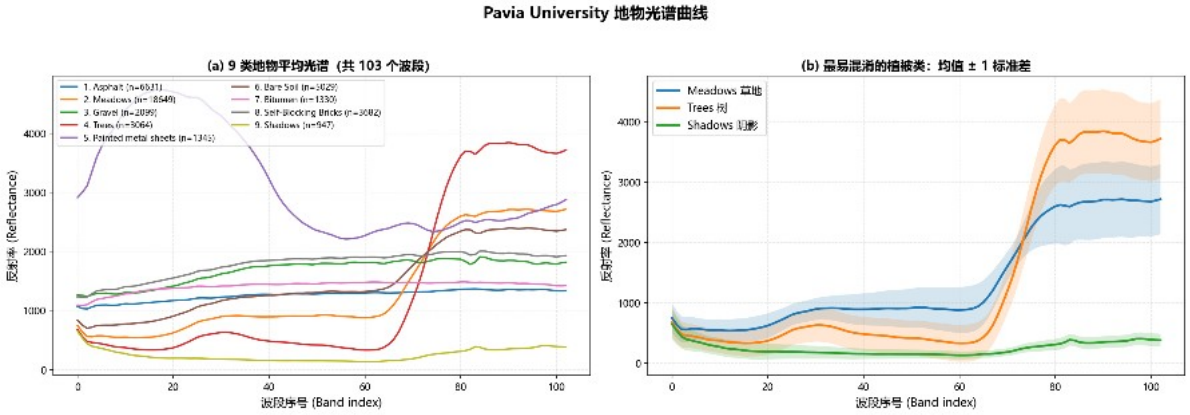
## 八、独立探索：邻域对照实验与两类混淆机制

### 8.1 问题的由来

基线复现的混淆矩阵显示：13 例错分中，**10 例（76.9%）集中于 `Trees → Meadows` 这一条路径。**

本节从光谱特征与空间邻域两个角度分析该现象的成因，并通过严格控制系统变量的对照实验分离其影响因素。

## 8. 2 光谱证据




由各类地物平均光谱曲线可得三点观察：

| 观察 | 含义 |
|---|---|
| **波段 65–70 存在集体拐点（红边效应）** | 近红外波段是区分植被与非植被的关键区域 |
| **Trees 与 Meadows 的光谱曲线形状高度相似** | 二者在光谱维度上差异较小 |
| **Trees 的 ±1σ 区间最宽（近红外区约 2800–4400）** | 类内离散度大，个别像元易于越界 |

进一步的类间光谱角分析显示：36 对地物中，光谱角最小的 7 对（0.96°–11.03°）在基线上**全部零错分**，

而第一个出现混淆的 Trees ↔ Meadows（15.74°）仅排第 8。这说明**光谱形状相似度不能直接预测分类混淆。**

## 8. 3 研究假说：邻域污染

| 步骤 | 内容 |
|---|---|
| ① | PU 数据集空间分辨率为 1.3 m/像元，25 × 25 的 patch 覆盖 **32.5 m × 32.5 m** |
| ② | PU 为城区影像，地物斑块较为破碎，32.5 m 的窗口**必然跨越多个类别** |
| ③ | 地物边界处「树」像元的邻域**被 Meadows（最大类，占比 43.6%）主导** |
| ④ | 模型将其判别为 Meadows —— 即「邻域污染」 |

## 8. 4 验证的难点与方案设计

**难点**：最直接的方法是缩小 patch 尺寸，但该操作会同时改变模型本身。

| 若将 patch 尺寸由 25 缩减至 11 | 影响 |
|---|---|
| **展平特征维度** | 18,496 → 576 |
| **全连接层参数量** | 4,735,232 → 147,712 |

| | |
|---|---|
| **模型总参数量** | 4,844,793 → **257,273（减少 94.7%）** |

此时即便性能发生变化，也无法确定其来源是「邻域污染减少」还是「模型容量下降」。

**方案设计**：

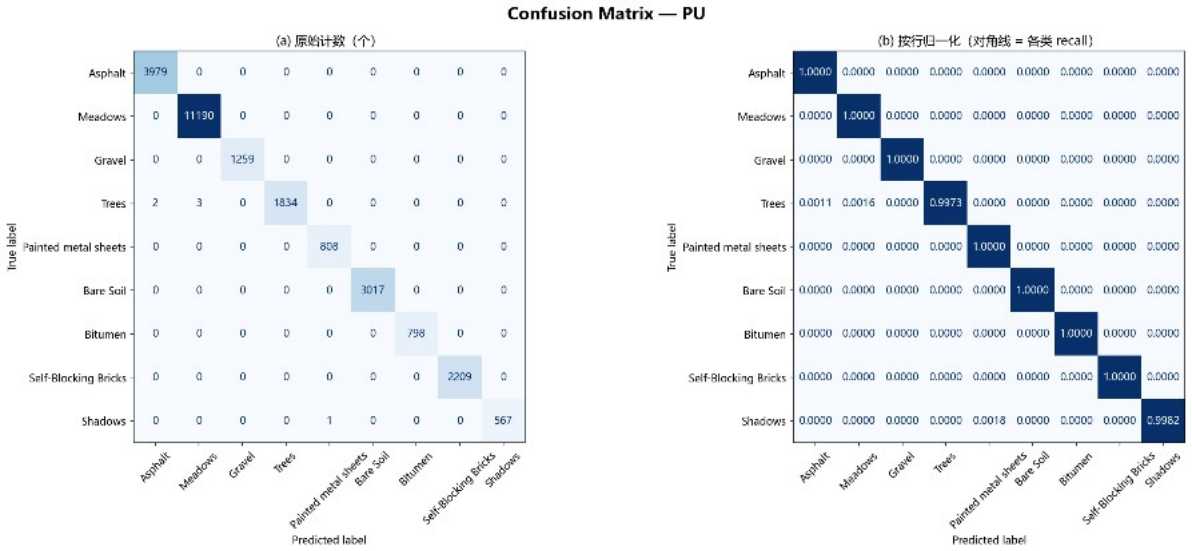
| 项目 | 方案 A：缩小 patch | 方案 B：25×25 + 中心 11×11 置零 |
|---|---|---|
| **做法** | patch 尺寸改为 11 | 输入张量仍为 25×25，外围 7 圈置 0 |
| **有效邻域** | 11×11 | 11×11 |
| **参数量** | 257,273（−94.7%） | **4,844,793（完全一致）** |
| **计算量** | 3.49 M（−93.1%） | **50.95 M（完全一致）** |
| **变化的因素数** | **2 个**（邻域 + 容量） | **1 个**（仅邻域） |

方案 B 的直观含义：模型接收的输入尺寸仍为 25 × 25，但除中心 11 × 11 区域外，其余部分的信息均为零 ——

即**模型结构不变，仅有效信息范围改变。**

### 8.5 结果

| 指标 | 原实验（25×25 全信息） | 方案 B（11×11 置零） | 变化 |
|---|---|---|---|
| **OA** | 0.9994935 | **0.9997662** | **+0.0273 pp** |
| **AA** | 0.9992247 | **0.9995023** | **+0.0278 pp** |
| **Kappa** | 0.9993287 | **0.9996902** | **+0.0362 pp** |
| **错分像元** | 13 | **6** | **−7（减少 54%）** |
| **参数量** | 4,844,793 | 4,844,793 | 完全一致 |
| **计算量** | 50.95 M | 50.95 M | 完全一致 |




## 8. 6 因素分离与两类混淆机制

| 错误路径 | 原实验 | 方案 A（邻域↓ + 容量↓95%） | 方案 B（仅邻域↓） |
|---|---|---|---|
| **Trees → Meadows** | 10 | 4 | 3 |
| **Trees → Asphalt** | 2 | 0 | 2 |
| **Asphalt → Bitumen** | 0 | **4** | **0** |
| **Asphalt → Bare Soil** | 0 | **2** | **0** |
| **Self-Blocking Bricks → Gravel** | 0 | **2** | **0** |
| **Self-Blocking Bricks → Asphalt** | 0 | 1 | 0 |
| **Shadows → Asphalt** | 0 | 1 | 0 |
| **Shadows → Painted metal sheets** | 0 | 0 | 1 |
| **Self-Blocking Bricks → Trees** | 1 | 0 | 0 |
| **总错分** | **13** | **15** | **6** |

**归因结论**：

| 观察 | 方案 A（两因素同时变化） | 方案 B（仅邻域变化） | 归因结论 |
|---|---|---|---|
| **Trees 错分** | 12 → 4 | 12 → 5 | 源于**邻域污染** |
| **Asphalt 错分** | 0 → 7 | 0 | 源于**模型容量不足** |
| **Self-Blocking Bricks 错分** | 1 → 3 | 0 | 同上 |

由此可对高光谱分类中的混淆作机制层面的区分：

| 维度 | 类型 A：邻域污染型 | 类型 B：光谱相似型 |
|---|---|---|
| **代表** | Trees ↔ Meadows | Asphalt ↔ Bitumen（1.81°）、Gravel ↔ Self-Blocking Bricks（0.96°） |
| **成因** | 边界像元的邻域被多数类主导 | 判别容量不足，难以区分光谱高度相似的类别 |
| **优化方向** | 缩减有效邻域 | 增加或保持模型容量 |
| **方向关系** | 两者相反 | |

**该结论说明：单一配置难以在所有类别上同时取得最优性能。**

### 8.7 实用建议与参数冗余发现

**实用建议**：在 PU 类城区高光谱数据上，将 patch 的有效邻域缩减至 **11×11 ~ 15×15**，

在不增加任何参数与计算成本的前提下，可将 OA 由 99.949% 提升至 99.977%、错分像元由 13 降至 6。

**参数冗余**：参数量减少 94.7%、计算量减少 93.1% 时，OA 仅下降 0.0078 pp、AA 仅下降 0.0008 pp；

冗余集中于第一个全连接层（占全模型参数量 **97.7%**）。即以 6.9% 的计算量达到 99.94% 的总体精度。

> ***附注***：*论文直接采用 25 × 25 的 patch，但未说明选取依据，亦未开展邻域尺寸的敏感性分析；本实验对该问题进行了补充。*

## 九、实验局限

| # | 局限 | 影响 | 改进方向 |
|---|---|---|---|
| **1** | 消融实验**参数量不对等**（纯 3-D 版 +84%） | 该组精度差异无法纯归因于结构 | 对齐参数量/FLOPs 后重测 |
| **2** | 各配置均为**单次运行** | 3–11 个像元的差异处于波动边缘，未做显著性检验 | 每组重复 3–5 次，报告均值 ± 标准差 |
| **3** | **仅在 PU 数据集验证** | 结论能否迁移至 IP / SA 未知 | 在 IP、SA 上重复 |
| **4** | **未做参数量/FLOPs 对齐的严格对照** | "纯 2-D 更优"的结论受 FLOPs 差异（−75%）混淆 | 设计等 FLOPs 对照 |
| **5** | 光谱角为**单变量、逐波段**的粗略度量 | 无法反映多维联合可分性 | 补充 Jeffries–Matusita 距离、多维可分性分析 |
| **6** | 少数类错分可能含**标注噪声** | 追求 100% 可能是在拟合标注误差 | 人工核查错分像元位置 |
| **7** | 未做 **PCA 主成分数**与 **patch 尺寸**的敏感性分析 | 最优配置可能未找到 | 补充超参扫描 |

## 十、结论

1. **成功复现** HybridSN 在 Pavia University 上的结果：OA = **99.949%**、AA = **99.922%**、Kappa = **99.933%**（测试集 25,667 个像元），与论文报告的 99.98% 处于同一水平。
2. **训练样本比例实验**表明：精度随样本增加而提升但边际递减（20% → 30% 已饱和）；

**OA 与 AA 的差距随样本减少单调扩大 21 倍**，证明 **AA 比 OA 更能暴露少数类的失效。**

3. **消融实验**表明：**Dropout 是有效的正则化手段**（移除后 OA −0.043 pp、错分 +85%）；

且 Dropout 显著抑制训练尖峰（无 Dropout 时出现 loss 放大 224 万倍的灾难性崩塌）。

检查点机制实际规避了一次性能损失。

4. **移除 2-D 卷积阶段仅损失 0.0117 pp 的 OA**，但 AA 降幅为 OA 的 3.78 倍、OA − AA 差距扩大 2.21 倍。

同时该配置参数量反而增加 84%，说明 2-D 卷积是"参数少但计算密集"的模块。

5. ⭐ **在参数量对等（−1.0%）的条件下，纯 2-D-CNN baseline 取得相当的 OA 与更高的 AA，

且计算量仅为 HybridSN 的 25% —— 论文"混合结构优于单一 2-D 结构"的主张在本实验协议下未获支持**。

6. ⭐ **光谱角与混淆矩阵的交叉分析推翻了朴素直觉**：

光谱角最小的 7 对地物（0.96°–11.03°）**全部零错分**，而第一个出现混淆的 Trees ↔ Meadows（15.74°）

其类内离散度为全图最大。**决定混淆的是"均值差 ÷ 类内波动"，而非"均值差"本身。**

7. **两组消融均呈现"AA 降幅 > OA 降幅"**（1.70 倍与 3.78 倍），与训练比例实验的规律一致 ——

**"AA 比 OA 更能暴露少数类失效"是稳健结论。**

## 十一、复现说明

### 10.1 代码与数据

```
HybridSN-HSI-Classification/
├── README.md                    # 项目说明（含来源声明与主要结果）
├── requirements.txt             # 依赖清单
├── LICENSE                      # 许可与来源说明
```

```
├── .gitignore                    # 排除数据集与模型权重
├── HybridSN.ipynb                # 主实验代码（含全部输出）
├── HybridSN.py                   # 脚本版
├── check_env.py                  # 环境自检
├── docs/                         # 实验报告（PDF / Word）与各实验分析文档
├── figures/                      # 全部结果图（19 张）
├── results/                      # 各的分类告与
│   ├── PU_tr30/                  # 基线（30% 训练）
│   ├── PU_tr05/ PU_tr10/ PU_tr20/   # 训练比例对比实验
│   ├── ablation_nodropout/       # 消融① 移除 Dropout
│   ├── ablation_no2dconv/        # 消融② 移除 2-D 卷积
│   ├── ablation_2dcnn_only/      # 消融③ 纯 2-D-CNN
│   ├── opt6_nir1/                # 独立探索：移除光谱方向卷积
│   ├── opt2_patch11/             # 独立探索：patch 缩至 11
│   └── opt2b_mask11/             # 独立探索：11×11 置零
└── dataset/                      # 数据放置说明（原始数据不随仓库上传）
```

### 10.2 复现步骤

```
# 1. 安装依赖
pip install -r requirements.txt

# 2. 环境自检
python check_env.py

# 3. 运行主实验（或直接运行 HybridSN.ipynb）
python HybridSN.py
```

**随机性控制**：`RANDOM_SEED = 666`，同时固定 `random` / `numpy` / `torch` / `torch.cuda` 四处种子；

数据划分使用 `train_test_split(..., stratify=y, random_state=100)`。

**可复现性验证**：消融① 的两次独立运行结果**逐位相同**（OA 均为 0.9990649472084778），

证明在移除 Dropout 后，本实验环境下的训练过程完全确定。

## 附录：数据文件对照表

| 实验组 | 结果目录 | 关键文件 |
|---|---|---|
| **基线（30% 训练）** | results/PU_tr30/ | classfication_report.txt + loss/train_acc/val_acc.csv |
| **训练比例 5%** | results/PU_tr05/ | classfication_report.txt |
| **训练比例 10%** | results/PU_tr10/ | 同上 |
| **训练比例 20%** | results/PU_tr20/ | 同上 |
| **消融① 无 Dropout** | results/ablation_nodropout/ | classfication_report.txt + 三个 CSV |
| **消融② 纯 3-D** | results/ablation_no2dconv/ | 同上 |
| **消融③ 纯 2-D** | results/ablation_2dcnn_only/ | 同上 |
| **独立探索：移除光谱方向卷积** | results/opt6_nir1/ | 同上 |
| **独立探索：patch 缩至 11** | results/opt2_patch11/ | 同上 |
| **独立探索：11×11 置零** | results/opt2b_mask11/ | 同上 |

*本报告由复现实验数据生成，所有数值均可在 `results/` 目录下对应文件中核验。*